

Prosjekt Rapport

Rumex Deteksjon

Fabian Heflo

Introduksjon

Målet med prosjektet er å trenne opp en modell som kan detektere høymole (rumex) fra dronebilder. Formålet er å fjerne høymolen som er et problem i landbruk. Høymole er en plante som sprer seg svært fort og som inneholder oksalsyre som gir vond smak. Den befinner seg ofte i beite og enger hvor husdyr får dårlig kvalitet og mengde før.

Data og Preprosesering

I denne oppgaven valgte jeg å bruke Tingvold Large (54)-datasettet. Dette dekker et område på omtrent 31 dekar og består av rundt 2700 bilder tatt med en gimbalvinkel på 40°. Jeg valgte dette datasettet fordi jeg ønsket en mer realistisk og utfordrende case der både datamengden og variasjonen i bildene stiller krav til preprosessering og modelltrenings.

Skrå kameravinkler og varierende lysforhold gjør annoteringen mer krevende, men gir samtidig et mer robust grunnlag for å utvikle en modell som kan generalisere til reelle droneforhold. Den store datamengden åpner også for å undersøke hvordan ulike preprosesserings- og augmenteringsstrategier påvirker modellens ytelse.

Jeg gjennomførte en analyse av pikselverdi-fordelingen for alle fem droneruter og fant at lys- og kontrastnivåene var relativt konsistente på tvers av rutene. Dette indikerte at datasettene hadde jevne eksponeringsforhold, og at kun mindre justeringer eventuelt ville være nødvendige. På bakgrunn av dette valgte jeg å gå videre med treningen uten omfattende bildejusteringer, for å se hvordan modellen presterer på relativt rå data.

Datasettet består av fem droneruter med et varierende antall bilder. Jeg trakk tilfeldig omtrent like mange bilder fra hver rute (≈ 20 bilder per rute), totalt 100 bilder. Disse ble lastet opp i Label Studio for annotering. Annoteringen var tidkrevende, og siden jeg hadde begrenset erfaring med Rumex som art, valgte jeg å bruke én enkelt klasse for enkelhetens skyld. Det er noe usikkerhet knyttet til annoteringsnøyaktigheten, men jeg valgte heller å være litt for inkluderende enn å risikere at modellen ikke gjenkjenner reelle forekomster.

Til slutt ble de annoterte dataene eksportert fra Label Studio i YOLO-format, som gir ett bildefil (.jpg) og én tilhørende tekstfil (.txt) med bounding box-koordinater per bilde. Jeg delte datasettet inn i tre deler: 70 % for trening, 20 % for validering og 10 % for testing.

Metode

Modellen som ble brukt i dette prosjektet er YOLOv11, implementert via Ultralytics-rammeverket. Jeg startet med å trenere YOLO11-small med standardparametere for å etablere et utgangspunkt. Resultatene fra denne modellen var imidlertid ikke tilfredsstillende, og jeg valgte derfor å utføre hyperparametertuning for å forbedre ytelsen.

Tuningen ble gjort ved hjelp av funksjonen `tune()` fra Ultralytics-biblioteket, som utfører automatisk søk etter optimale hyperparametere. Jeg kjørte 50 epochs med 20 iterasjoner, og benyttet AdamW som optimizer ettersom denne ofte fungerer godt for mindre datasett med begrenset variasjon.

Jeg oppdaget i etterkant at modellen under tuningen ikke ble spesifisert, og at Ultralytics derfor brukte sin standardmodell (YOLO11-nano) i stedet for YOLO11-small. Dette var likevel fordelaktig, ettersom nano-modellen krever mindre ressurser og gjorde det mulig å fullføre tuningen på omtrent 12–13 timer på en Apple M1-chip.

Etter fullført tuning brukte jeg de optimaliserte hyperparametrene til å trenere en større modell, YOLO11-medium. Hensikten var å dra nytte av de funnene fra tuningen som et godt utgangspunkt («første gjetning») for en mer kapabel modell.

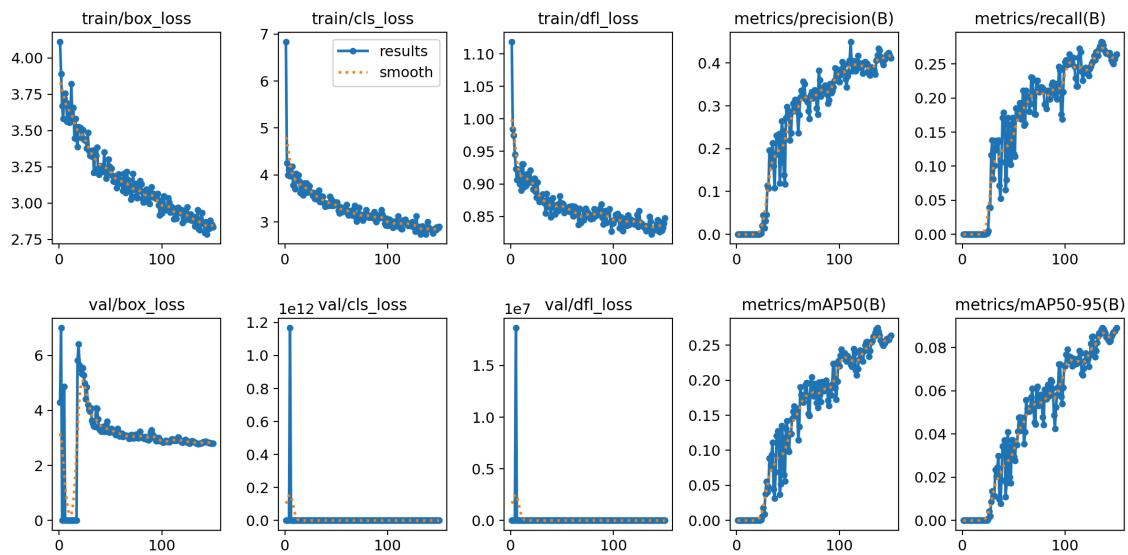
Modellens ytelse ble deretter evaluert ved hjelp av mean Average Precision (mAP@0.5), som måler hvor godt de predikerte bounding-boksene samsvarer med de faktiske annotasjonene.

Resultater

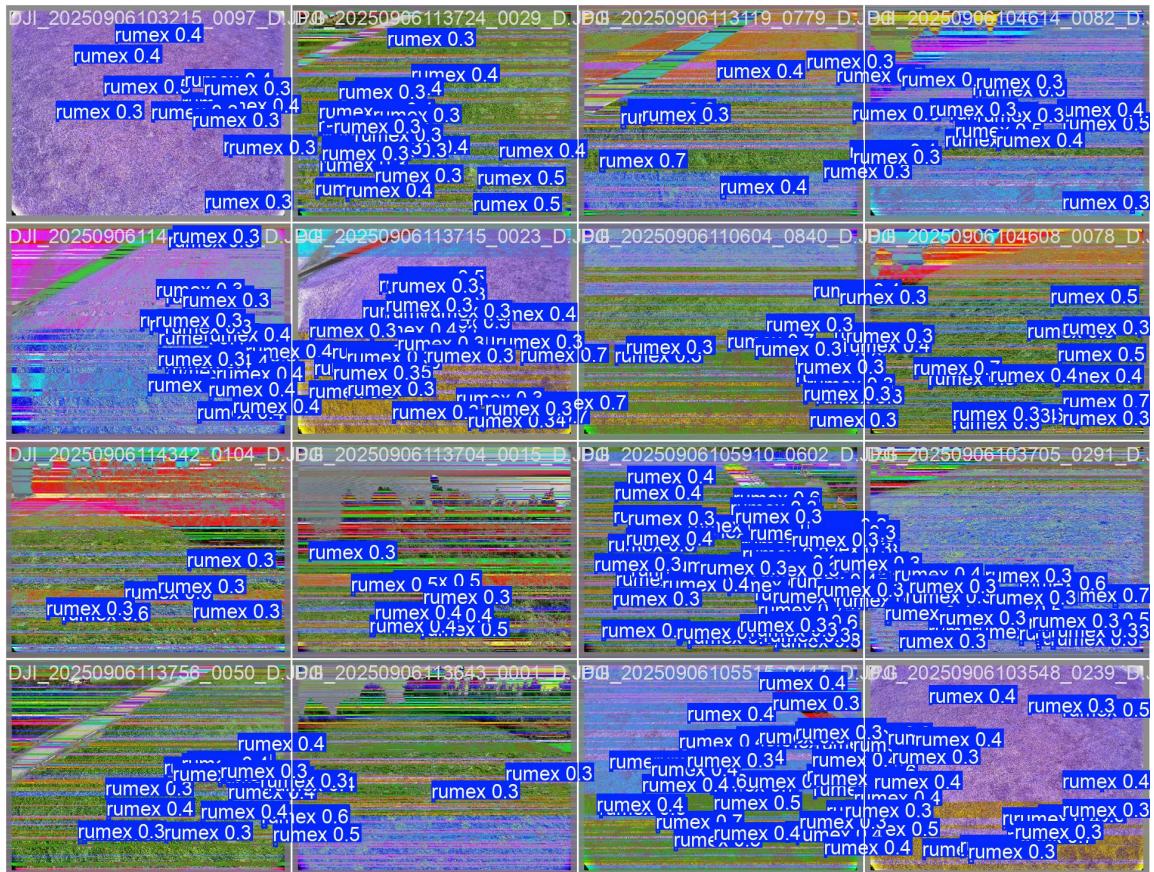
Treningsresultater

Tuningen av YOLO11-medium-modellen viste en jevn forbedring gjennom hele forløpet. Både trenings- og valideringstap sank gradvis og stabiliserte seg mot slutten av de 150 epokene, noe som indikerer at modellen lærte på en stabil måte uten tydelige tegn til overfitting.

Som vist i figur 1, falt box-loss fra omtrent 4,0 til under 3,0, mens classification-loss og DFL-loss viste en tilsvarende jevn reduksjon. Samtidig økte precision og recall kontinuerlig, og mAP@0.5 steg til rundt 0.25 mot slutten av treningen. Selv om dette nivået er moderat, viser resultatene at modellen klarer å identifisere Rumex-forekomster med rimelig nøyaktighet, gitt den begrensede datamengden og at treningen ble gjort på én enkelt klasse.



Figur 1: Utvikling av tap (train/val) og ytelsesmetrikkene precision, recall og mAP gjennom 150 epoker.



Figur 2: Eksempler på modellens prediksjoner fra valideringssettet etter ferdig trening. Hver blå boks markerer et område der modellen har identifisert Rumex, med tilhørende sannsynlighet (confidence score).

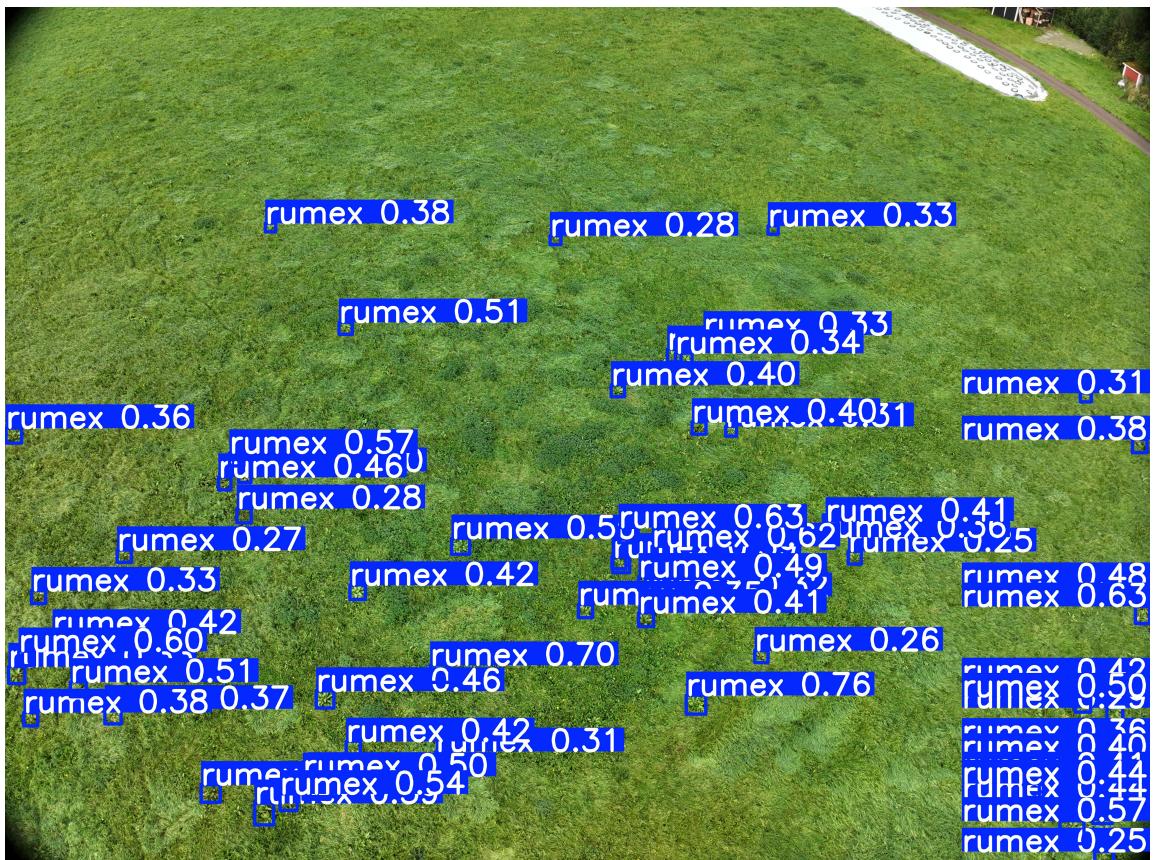
Figuren viser at modellen oppdager flere potensielle forekomster, men også noen overlappende og feilaktige deteksjoner, spesielt i områder med tett vegetasjon eller varierende belysning.

Samlet sett tyder treningsforløpet på at hyperparametertuningingen bidro til en stabil konvergens, og at modellen har et solid grunnlag for videre evaluering og testing.

Evaluering og Prediksjoner

Etter at treningen var fullført, ble den beste modellen (YOLOv11-medium) evaluert på testsettet for å måle hvor godt den generaliserte til nye data. Evalueringen ble gjort med standardmetrikkene mAP@0.5, presisjon og recall.

Modellen oppnådde en mAP@0.5 på 0.25, med en presisjon på omtrent 0.30 og en recall på rundt 0.27. Disse resultatene indikerer at modellen har lært å gjenkjenne Rumex-forekomster med moderat nøyaktighet, men fremdeles har utfordringer med å skille Rumex fra annen vegetasjon i komplekse omgivelser.



Figur 3: Modellens prediksjoner på testdata. Flere Rumex-forekomster blir identifisert korrekt. Flere tydelige Rumex-forekomster som ikke blir detektert.

Prediksjonene viser at modellen i hovedsak oppdager de mest tydelige forekomstene, men at den også genererer flere overlappende eller feilaktige deteksjoner i områder med tett vegetasjon eller store skygger. Dette skyldes trolig både begrenset treningsdata og at mange bilder har lik bakgrunn og fargetoner, som gjør det vanskelig for modellen å lære distinkte mønstre. Modellen sliter med å plukke opp alle de tydelige eksemplene på Rumex-forekomster. Den klarer en god del og gjør ikke en dårlig jobb med dem den klarer å detektere, men detekterer altså 'for få'.

Til tross for disse utfordringene viser resultatene at modellen faktisk har lært et grunnleggende mønster for Rumex, og at den kan brukes som et utgangspunkt for videre forbedring. Ved å øke antallet annoterte bilder og inkludere flere variasjoner i belysning, vegetasjon og kameravinkel, vil modellen sannsynligvis kunne oppnå betydelig bedre presisjon og stabilitet.

Diskusjon og Konklusjon

Prosjektet viser hele arbeidsflyten i et data-drevet bildeanalyseprosjekt, fra utforskning av rådata til trening og evaluering av en ferdig modell. Selv om resultatene ikke oppnådde svært høy presisjon, demonstrerer arbeidet at YOLO11 kan brukes effektivt til å identifisere Rumex fra dronebilder, selv med et begrenset og enkelt datasett.

En viktig observasjon er at datakvaliteten og mengden annoterte bilder har stor innvirkning på modellens ytelse. Mange bilder inneholder lik bakgrunn, skygger eller overlappende planter, noe som gjør det vanskelig å skille Rumex fra annen vegetasjon. I tillegg ble kun én klasse brukt, noe som forenklet treningen, men også reduserte modellens evne til å lære mer nyanserte forskjeller.

Hyperparametertuningene viste seg å være nyttig for å stabilisere treningen og redusere tapet, men resultatene tyder på at modellen fremdeles kunne haft nytte av flere dataaugmenteringer og et større utvalg av treningsbilder. Et naturlig neste steg ville være å øke antall annotasjoner, inkludere flere klasser (for eksempel "usikker" vegetasjon).

Til tross for begrensningene har prosjektet gitt verdifulle erfaringer med hele prosessen fra datahåndtering til modelltrenings og evaluering. Modellen viser et lovende utgangspunkt som, med mer data og bedre annotering, kan videreføres til et robust verktøy for automatisk deteksjon av høymole i dronebilder.